

Text-driven 2D Human Pose Generation via Diffusion in Directional Angle Space

Kwon Bo Mi[†] · Lee Ki Yong^{††}

ABSTRACT

With the recent advances in text-driven generative technologies, research on generating human poses from natural language has attracted increasing attention. This paper proposes a directional-angle-based diffusion model for generating 2D skeleton poses from natural language text. Conventional joint-coordinate-based methods have difficulty explicitly reflecting the geometric constraints of the human body, which may lead to structurally inconsistent poses. To address this limitation, we introduce a directional angle representation that expresses the direction of each bone using azimuth(θ) and elevation(ϕ), and directly model this representation as the output space of a DDPM(Denoising Diffusion Probabilistic Models). The proposed method is based on a two-stage framework that separates text classification from pose generation. A class-conditional diffusion model first generates directional-angle-based poses, and forward kinematics is then applied to reconstruct structurally consistent poses. Experimental results show that the proposed method improves semantic consistency by about 20 points over a coordinate-based baseline and enables structurally stable pose generation.

Keywords : Human pose generation, diffusion model, directional angle representation, text-driven generation

방향각 공간에서의 확산 모델을 이용한 텍스트 기반 2D 인체 포즈 생성

권 보 미[†] · 이 기 용^{††}

요 약

최근 텍스트 기반 생성 기술의 발전에 따라, 자연어로부터 인체 포즈를 생성하는 연구가 주목받고 있다. 본 논문에서는 자연어 텍스트로부터 정적 2D 스켈레톤 포즈를 생성하기 위한 방향각 기반 확산 모델을 제안한다. 기존의 관절 좌표 기반 방법은 인체의 기하학적 제약을 명시적으로 반영하기 어려워 구조적으로 일관적이지 않은 포즈를 생성할 수 있다는 한계를 가진다. 이를 해결하기 위해 본 연구에서는 각 뼈대의 방향을 방위각(azimuth, θ)과 고도각(elevation, ϕ)으로 표현하는 방향각(directional angles) 기반 표현을 도입하고, 이를 DDPM(Denoising Diffusion Probabilistic Models)의 생성 공간으로 직접 모델링한다. 제안 방법은 텍스트 분류와 포즈 생성을 분리한 2단계 구조를 기반으로 하며, 클래스 조건부 확산 모델을 통해 방향각 기반 포즈를 생성한 뒤 순방향 기구학(forward kinematics)을 적용하여 구조적으로 일관된 포즈를 복원한다. 실험 결과, 제안 방법은 기존 좌표 기반 접근 대비 의미 일관성 지표에서 약 20%p 향상된 성능을 보였으며, 구조적으로 안정적인 포즈 생성이 가능함을 확인하였다.

키워드 : 인체 포즈 생성, 확산 모델, 방향각 표현, 텍스트 기반 생성

1. 서 론

인체 포즈 생성(human pose generation)은 3D 애니메이션, 가상현실(VR), 스포츠 동작 분석, 게임 캐릭터 제어 등 다

양한 분야에서 활용되는 핵심 기술이다. 특히 자연어 텍스트로부터 인체 동작을 생성하는 기술은 전문적인 지식 없이도 사용자의 의도를 직관적으로 반영한 포즈를 생성할 수 있다는 점에서 높은 활용 가치를 가진다.

최근에는 확산 모델(diffusion model)의 발전으로 텍스트 조건부 인체 모션 생성 연구가 활발히 이루어지고 있다. 대표적으로 텍스트로부터 3차원 인체 모션 시퀀스를 생성하는 Motion Diffusion Model(MDM)[1]과 MotionDiffuse[2]는 모션 생성에서 유의미한 성능을 보였다. 이러한 접근들은 주로 관절의 3차원 좌표를 직접 생성하는 방식에 초점을 맞추고 있

※ 이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원·학·석사연계ICT핵심인재양성사업의 지원을 받아 수행된 연구임(IITP-2026-RS-2022-00156299)

† 준 회원 : 숙명여자대학교 컴퓨터과학과 석사과정

†† 종신회원 : 숙명여자대학교 소프트웨어학부 교수

Manuscript Received : April 7, 2026

Accepted : April 24, 2026

* Corresponding Author : Lee Ki Yong(kiyonglee@sookmyung.ac.kr)

다[3]. 그러나 관절 좌표 기반 표현은 인체의 기하학적 제약을 명시적으로 반영하기 어렵다는 한계를 가진다. 인체 포즈는 뼈대 길이 보존, 관절 간 상대적 관계 등 구조적 제약을 만족해야 하지만, 좌표 기반 생성 방식에서는 각 관절이 독립적으로 생성되기 때문에 이러한 제약이 충분히 반영되지 않을 수 있다. 그 결과, 생성된 포즈가 구조적으로 왜곡되거나 물리적으로 비현실적인 형태를 포함하는 문제가 발생할 수 있다. 이러한 문제를 해결하기 위해 인체 포즈를 각도 기반으로 표현하는 접근이 고려될 수 있다. 각도 표현은 뼈대 간 상대적 방향 관계를 직접 모델링함으로써 인체 구조를 자연스럽게 반영할 수 있으며, 순방향 기구학(forward kinematics)을 통해 구조적으로 일관된 포즈 복원이 가능하다. 현재 이러한 각도 표현을 생성 모델의 출력 공간으로 직접 활용하는 연구는 아직 제한적인 상황이다.

본 논문에서는 방향각(directional angles) 기반 표현을 생성 공간으로 직접 모델링하는 텍스트 기반 인체 포즈 생성 확산 모델을 제안한다. 제안 방법은 각 뼈대의 방향을 방위각(azimuth, θ)과 고도각(elevation, ϕ)으로 표현하여 22차원 포즈 벡터를 구성하였다. 또한 사전 학습된 BGE-M3[4] 텍스트 인코더를 통한 텍스트 분류와 포즈 생성을 분리한 2단계 구조로 구성되며, 순방향 기구학(forward kinematics)으로 구조적으로 일관된 포즈 복원이 가능하도록 설계하였다.

HumanML3D 데이터셋을 기반으로 총 96,048개의 학습 데이터를 구축하여 모델을 학습하였으며, 의미 일관성(Semantic Consistency, SC), 분포 유사도(Fréchet Inception Distance, FID)[5], 다양성(Average Pairwise Distance, APD), 그리고 뼈대 길이 편차(Bone Length Deviation, BLD) 지표를 통해 성능을 평가하였다. 실험 결과, 제안 방법은 의미 일관성(SC) 90.7%를 달성하며 기존 좌표 기반 방법 대비 약 20%p 향상된 성능을 보였다. 또한 분포 유사도(FID) 0.54를 기록하여 실제 데이터 분포를 효과적으로 재현하였으며, 뼈대 길이 편차(BLD)가 0에 수렴하여 구조적으로 안정적인 포즈 생성이 가능함을 확인하였다.

본 논문의 구성은 다음과 같다. 2장에서는 관련 연구를 소개하고, 3장에서는 제안하는 방법을 설명한다. 4장에서는 데이터셋 구축을 포함한 실험 설정 및 결과를 제시하며, 5장에서 결론을 맺는다.

2. 관련 연구

2.1 확산 모델

확산 모델(diffusion model)은 데이터에 점진적으로 가우시안 노이즈를 추가하는 순방향 과정(forward process)과, 노이즈로부터 원본 데이터를 복원하는 역방향 과정(reverse process)으로 구성되는 확률적 생성 모델이다. Ho et al.[6]이 제안한 DDPM(Denoising Diffusion Probabilistic Models)은 신경망이 각 타임 스텝에서 추가된 노이즈를 예측하도록 학습

함으로써, 이미지 생성에서 높은 품질과 다양성을 달성하였다. 이후 Nichol and Dhariwal[7]은 노이즈 스케줄 개선을 통해 성능을 향상시켰으며, 확산 모델은 이미지, 오디오 등 다양한 도메인으로 확장되고 있다. 최근에는 텍스트 조건부 생성에도 확산 모델이 적용되어 복잡한 데이터 분포를 효과적으로 모델링하는 방법으로 활용되고 있다. 그러나 생성 성능은 모델 구조뿐 아니라 데이터 표현 방식에도 크게 의존하며, 표현 방식이 구조적 정보를 충분히 반영하지 못할 경우 생성 결과의 일관성이 저하될 수 있다. 본 논문에서는 이러한 관점에서, 인체 구조를 효과적으로 반영할 수 있는 각도 기반 표현 공간에서 동작하는 확산 모델을 제안한다.

2.2 인체 포즈 표현

인체 포즈를 수치적으로 표현하는 방법은 관절 좌표, 회전 표현, 각도 표현 등으로 구분된다. 관절 좌표 기반 표현은 각 관절의 3차원 위치를 직접 사용하여 직관적이지만, 뼈대 길이와 관절 간 기하학적 제약이 명시적으로 반영되지 않기 때문에 생성 과정에서 인체 구조가 왜곡되거나 물리적으로 비현실적인 포즈가 생성될 수 있다. 회전 기반 표현(예: 오일러 각도, 회전 행렬 등)은 관절의 회전을 보다 정확하게 표현할 수 있으나, 짐벌 락(gimbal lock)이나 SO(3) 공간의 비선형성으로 인해 모델 학습이 복잡해지는 문제가 존재한다. 이에 비해 각도 기반 표현은 뼈대 간의 상대적 관계를 직접 모델링함으로써 인체의 구조적 제약을 자연스럽게 반영할 수 있다. 또한, 인체의 연결 구조를 고정한 상태에서 포즈 변화에 해당하는 각도만을 모델링함으로써 표현의 효율성과 학습 안정성을 동시에 확보할 수 있다. 그러나 이러한 각도 표현을 생성 모델의 출력 공간으로 직접 활용한 연구는 제한적이며, 기존의 단순 각도 표현은 방향 정보를 충분히 반영하지 못하는 한계가 존재한다.

본 논문에서는 각도를 생성 공간으로 직접 모델링하는 확산 기반 프레임워크를 제안하며, 각 뼈대의 방향을 방위각(θ)과 고도각(ϕ)로 표현하는 방향각(directional angles) 기반 표현을 도입한다.

2.3 텍스트 기반 인체 포즈 및 모션 생성

텍스트로부터 인체 동작을 생성하는 연구는 다양한 생성 모델의 발전과 함께 활발히 이루어지고 있다. 초기에는 VAE와 같은 생성 모델 기반 접근이 제안되었으며[8], 이후 확산 모델의 도입으로 생성 품질과 다양성이 크게 향상되었다. 대표적으로 MDM[1]과 MotionDiffuse[2]는 텍스트 조건부 3차원 인체 모션 시퀀스를 생성하는 확산 기반 모델로, 이후 latent diffusion[9, 10], retrieval-augmented diffusion[11], 그리고 language modeling 기반 접근인 MotionGPT[12] 등 다양한 확장 연구로 발전하였다. 텍스트와 포즈 간의 관계를 명시적으로 모델링하기 위한 연구로 PoseScript[13]와 같이 자연어와 포즈 간의 대응 관계를 구축하는 접근도 제안되었



(A) Model Architecture**(B) Inference (Pose generation)**

Fig. 1. Proposed Method

다. 그러나 이러한 기존 연구들은 대부분 관절 좌표 기반 표현에 의존하고 있어, 표현 방식 자체 개선을 위한 접근은 상대적으로 제한적이다.

3. 제안 방법

3.1 전체 구조 개요

본 논문에서는 텍스트 분류와 확산 기반 포즈 생성을 분리한 2단계 파이프라인을 제안한다. Fig. 1은 제안 방법의 전체 구조를 보여준다. 1단계에서는 입력 텍스트를 사전 학습된 텍스트 인코더(BGE-M3)와 프로토타입 기반 분류기를 통해 sitting, walking, standing 중 하나의 포즈 클래스로 분류한다. 2단계에서는 분류된 클래스를 조건으로 하는 DDPM이 11개 뼈대의 방향각으로 구성된 22차원 포즈 벡터를 생성하고, 이를 순방향 기구학(forward kinematics, FK)을 통해 3차원 관절 좌표로 복원한 후 2차원 스켈레톤 포즈로 투영한다. Fig. 1A는 확산 모델의 구조를 나타낸다. 노이즈가 추가된 포즈 벡터(22D), 시간 임베딩(128D), 클래스 임베딩(32D)을 결합한 182차원 입력이 MLP를 통해 노이즈 $\hat{\epsilon}$ 를 예측한다. Fig. 1B는 추론 과정을 나타낸다. 가우시안 노이즈 X_T 에서 시작하여 DDPM의 반복적 디노이징을 통해 22차원 포즈 벡터 X_0 를 생성하며, 이를 고정된 기준 골격(base pose)과 함께 FK에 입력하여 3차원 관절 좌표를 산출한다. 기준 골격의 뼈 길이가 고정되어, 생성된 모든 포즈에서 해부학적 구조가 항상 보존된

다. 이러한 구조는 텍스트-포즈 쌍 데이터 없이도 포즈 생성을 가능하게 하며, 텍스트 이해와 포즈 생성을 분리함으로써 모델 복잡도를 낮추고 학습 안정성을 향상시킨다.

3.2 방향각 기반 포즈 표현

기존의 인체 포즈 표현은 주로 각 관절의 3차원 좌표를 직접 사용하는 방식이 활용된다. 이러한 접근은 직관적이고 구현이 간단한 장점이 있으나, 좌표 직접 생성의 경우 각 관절이 독립적으로 예측되어 뼈 길이가 일정하지 않고, 포즈의 의미적 차이가 여러 관절 좌표에 분산되어 클래스 조건에 따른 자세 변화를 효과적으로 학습하기 어렵다. 따라서 구조적 일관성이 떨어질 뿐만 아니라, 결과적으로 비현실적인 포즈 생성으로 이어질 수 있다. 본 논문에서는 이를 해결하기 위해 각 뼈대의 방향을 구면 좌표계 기반의 방향각, 즉 관절의 방위각(θ)과 고도각(ϕ)으로 표현한다. 각 뼈대의 단위 방향 벡터 $V = (v_x, v_y, v_z)$ 는 Equation (1)과 같이 정의된다.

$$\begin{aligned}\theta &= \text{atan2}(v_x, v_z), \theta \in (-\pi, \pi] \\ \phi &= \arcsin(v_y), \phi \in [-\frac{\pi}{2}, \frac{\pi}{2}]\end{aligned}\quad (1)$$

방위각(θ)은 수평 평면(X-Z)에서의 회전을, 고도각(ϕ)은 수직 방향의 기울기를 나타낸다. Fig. 2A는 3차원 좌표계에서 θ 와 ϕ 의 기하학적 정의를 보여준다. 단위 방향 벡터 $d(\theta, \phi)$ 는 Z축을 기준으로 θ 만큼 수평 회전한 후, 수평면으로부터 ϕ 만

(A) Angle Definition (B) Application to skeleton bones




Fig. 2. Representation of Directional Angles (θ, ϕ)

를 기울어진 방향을 가리킨다. Fig. 2B는 이를 실제 스켈레톤에 적용한 예시로, 각 뼈대의 방향이 θ (주황)와 ϕ (파랑)로 표현됨을 보여준다. 또한 atan2 함수를 사용함으로써 방향의 부호를 포함한 표현이 가능하다. 이러한 표현은 각 뼈대의 방향을 명시적으로 인코딩함으로써 좌표 기반 표현에서 발생하는 구조적 불안정성을 완화할 수 있다.

3.3 22차원 포즈 구성

본 연구에서는 HumanML3D의 21개 관절 중 인체 자세를 효과적으로 표현할 수 있는 11개의 주요 뼈대를 선택하고, 각 뼈대에 대해 (θ, ϕ) 로 표현되는 22차원 방향각 벡터를 구성한다. 선정된 11개 뼈대의 구성과 부모-자식 관절 간 연결 관계는 Table 1에 정리하였다. 각 뼈대는 부모 관절에서 자식 관절로 향하는 방향 벡터로 정의되며, 해당 벡터를 기준으로 방위각(θ)과 고도각(ϕ)이 계산된다. 이를 통해 인체의 전체 구조를 구성하는 주요 방향 정보를 효율적으로 표현할 수 있다. Fig. 3은 선택된 주요 뼈대와 방향각 정의를 시각적으로 나타낸다. 그림에서는 가독성을 위해 뼈대 인덱스만 표시하였으며, 방향각의 개념적 이해를 돕기 위해 특정 관절(예: [3]L_THIGH)에 대해서만 방향각(θ, ϕ)을 예시로 표현하였다.




Fig. 3. Selected Bones for Directional Angle Representation

3.4 클래스 조건부 확산 기반 포즈 생성

1) 텍스트 기반 포즈 클래스 분류

입력 텍스트는 사전 학습된 BGE-M3 텍스트 인코더를 통해 1024차원 임베딩 벡터로 변환된다. 이후 각 포즈 클래스의 프로토타입 임베딩과의 코사인 유사도를 계산하여 가장 높은 값을 갖는 클래스를 선택한다. Equation (2)에서 z_{input} 은 입력 텍스트의 임베딩 벡터, z_c 는 클래스 c 의 프로토타입 임베딩, C 는 포즈 클래스 집합을 나타낸다. 각 클래스의 프로토타입은 해당 클래스를 대표하는 텍스트들의 평균 임베딩으로 사전 정의된다. 이 방식은 별도의 분류 모델 학습 없이 동작하며, 새로운 클래스 추가 시에도 유연하게 확장이 가능하다.

$$\hat{c} = \operatorname{argmax}_{c \in C} \frac{z_{input} \cdot z_c}{|z_{input}| |z_c|} \quad (2)$$

2) 순방향 과정

포즈 벡터 $x_0 \in R^{22}$ 에 대해 T 단계에 걸쳐 가우시안 노이즈

Table 1. Bone Configuration for 22-dimensional Directional Angle Representation

Index	Bone Name	Parent Joint	Child Joint	Body Part
0	SPINE_BASE	Pelvis	Spine_low	Lower Spine
1	SPINE_MID	Spine_low	Spine_mid	Middle Spine
2	SPINE_TOP	Spine_mid	Spine_up	Upper Spine
3	L_THIGH	L_Hip	L_Knee	Left Thigh
4	R_THIGH	R_Hip	R_Knee	Right Thigh
5	L_SHIN	L_Knee	L_Ankle	Left Shin
6	R_SHIN	R_Knee	R_Ankle	Right Shin
7	L_UPPER_ARM	L_Shoulder	L_Elbow	Left Upper Arm
8	R_UPPER_ARM	R_Shoulder	R_Elbow	Right Upper Arm
9	L_FOREARM	L_Elbow	L_Wrist	Left Forearm
10	R_FOREARM	R_Elbow	R_Wrist	Right Forearm

를 추가하는 순방향 과정은 Equation (3)과 같다. 노이즈 스케줄은 $\beta_1 = 10^{-4}$ 에서 $\beta_T = 0.03$ 까지 선형 증가하며, $T=100$ 을 사용한다.

$$q(x_t | x_0) = N(x_t; \sqrt{\alpha_t} x_0, (1 - \alpha_t)I)$$

$$\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s) \quad (3)$$

3) 역방향 과정

클래스 조건 c 와 타임스텝 t 를 입력으로 받아 노이즈를 예측하는 모델 f_θ 를 학습한다. 입력은 노이즈가 추가된 포즈 벡터(22D) x_t , 타임스텝 임베딩(128D) e_t , 클래스 임베딩(32D) c 를 결합한 182차원 벡터이다. 모델은 182→512→512→256→22 구조의 MLP로 구성되며, 각 은닉층에는 GELU 활성화 함수를 사용한다. 타임스텝 임베딩은 사인, 코사인 기반 위치 인코딩으로 정의된다. 클래스 임베딩은 3개의 포즈 클래스를 32차원 벡터로 매핑하는 임베딩 테이블로 구성되며, 모델이 클래스별 노이즈 분포 차이를 학습하도록 한다. 추론 시에는 가우시안 노이즈 $x_T \sim N(0,1)$ 에서 시작하여, 학습된 모델의 노이즈 예측을 기반으로 DDPM 샘플링을 따라 $t = T$ 부터 $t = 1$ 까지 단계적 디노이징을 통해 최종 방향각 벡터 x_0 을 생성한다.

$$\hat{\epsilon}_\theta = f_\theta([x_t; e_t; c]) \quad (4)$$

4) 학습 목표

모델은 예측 노이즈와 실제 노이즈 간의 평균 제곱 오차(MSE)를 최소화하도록 학습된다. Equation (5)는 Ho et al.[6]이 제안한 목적 함수로, DDPM의 변분 하한(variational lower bound)에서 가중치 항을 제거한 형태이다. 학습 시 각 반복에서 타임스텝 t 를 균일하게 샘플링하고, 해당 시점의 노이즈 ϵ 을 생성하여 모델이 이를 복원하도록 학습한다.

$$L = E_{x_0, t, \epsilon} [\| \epsilon - \hat{\epsilon}_\theta(x_t, t, c) \|^2] \quad (5)$$

5) 순방향 기구학(Forward Kinematics)

생성된 방향각은 Equation (6)과 같이 단위 방향 벡터로 변환된다. 이후 Equation (7)을 통해 부모 관절로부터 자식 관절의 위치를 순차적으로 계산하여 전체 포즈를 복원한다. l 은 기준 포즈(base pose)에서 계산된 뼈 길이이며, 별도의 과정 없이도 기하학적으로 일관된 포즈를 생성할 수 있게 한다. P_c = child joint position, P_p = parent joint position을 의미한다.

$$d = \begin{pmatrix} \cos\phi \sin\theta \\ \sin\phi \\ \cos\phi \cos\theta \end{pmatrix} \quad (6)$$

$$P_c = P_p + d \cdot l \quad (7)$$

4. 실험

4.1 데이터셋 구축

1) HumanML3D 데이터셋

본 연구는 HumanML3D[3] 데이터셋을 원천 데이터로 사용한다. HumanML3D는 AMASS[14] 및 HumanAct12[15] 데이터를 기반으로 구축된 데이터셋으로, 21개 관절의 3D 좌표 시퀀스와 동작을 설명하는 자연어 텍스트가 쌍으로 제공된다. 본 연구에서는 학습 분할(train split)에 해당하는 4,888개의 모션 시퀀스를 사용하였다.

2) 포즈 클래스 분류

각 모션 시퀀스는 동작 설명 텍스트를 기반으로 세 가지 포즈 클래스 중 하나로 분류된다. 텍스트 내 키워드를 정규 표현식으로 탐색하며, 각 클래스의 매칭 키워드는 Table 2와 같다. 물구나무서기(handstand), 공중제비(somersault) 등 비정상적인 자세를 포함하는 시퀀스는 제외 키워드를 통해 사전에 제거한다. 복수의 클래스 키워드가 동시에 탐지되는 경우는 빈도 기반 다수결을 적용하며, 세 클래스 모두 매칭되지 않는 시퀀스는 데이터셋에서 제외한다.

3) 포즈 프레임 선택 기준

모션 시퀀스는 수백 개의 프레임으로 구성되며, 그중 전형적인 정적 포즈를 대표하는 프레임만을 선별한다. 선택 기준은 클래스별 동작의 물리적 특성을 기반으로 설계하였다. 또한 특정 시퀀스가 데이터셋을 과도하게 지배하는 것을 방지하




Fig. 4. Dataset Construction Pipeline

Table 2. Text classification keywords by pose class

Class	Keywords	Excluded
sitting	sit, sitting, seated, seat, chair, crouch, squat, kneel	handstand, cartwheel
walking	walk, walking, step, stride, jog, run, march, pace	somersault, backflip
standing	stand, standing, upright, idle, stationary, still	frontflip, headstand

기 위해, 시퀀스당 최대 선택 프레임 수를 sitting 8개, walking 8개, standing 5개로 제한하였다.

먼저, sitting 클래스는 골반(pelvis)의 높이 감소를 주요 특징으로 한다. HumanML3D 좌표계에서 직립 상태의 골반 Y 좌표는 일반적으로 800 이상이며, 착석 시에는 크게 감소한다. 이에 따라 골반 Y 좌표가 550 이하인 프레임을 1차적으로 선택하였다. 신체 비율 차이를 고려하여, 클립 내 골반 Y 좌표가 하위 40% 이하인 프레임을 추가 기준으로 적용하고, 두 조건 중 더 엄격한 값(min(550, 하위 40% 기준))을 최종 임계값으로 사용하였다. 또한 앉는 과정의 동작 프레임을 제거하기 위해 전체 관절의 평균 속도가 클립 내 상위 60% 이하인 프레임만을 선택하였다.

walking 클래스는 보행 동작의 핵심 특징인 보폭(stride)을 기준으로 프레임을 선택한다. 좌측 발목(L_Ankle)과 우측 발목(R_Ankle)의 수평면(X-Z) 거리로 stride를 정의하며, Equation (8)과 같이 계산한다. 각 프레임의 stride가 해당 클립의 평균 stride 이상인 경우를 선택하였다. 클립마다 보행 속도와 보폭이 상이하므로 상대적 기준을 적용하기 위함이다.

$$stride(t) = \| P_{L_Ankle(t)_x} - P_{R_Ankle(t)_x} \|_2 \quad (8)$$

마지막으로, standing은 신체 움직임이 최소화된 정지 상태로 정의한다. 이를 위해 Equation (9)와 같이 전체 관절의 평균 이동 속도를 계산하고, 이 값이 클립 내 하위 30% 이하인 프레임을 선택하였다. 이는 직립 상태에서도 존재하는 미세한 움직임을 허용하면서 과도한 동작을 제거하기 위함이다.

$$vel(t) = \frac{1}{J} \sum_{j=1}^J \| P_j(t) - P_j(t-1) \|_2 \quad (9)$$

4) 데이터 증강

선별된 원본 프레임에 대해 두 가지 증강을 적용한다. 먼저, 좌우 미러링으로 모든 포즈의 좌우 대칭 샘플을 생성한다. 이는 방위각 θ 의 부호 반전과 좌우 뼈대 쌍 교환을 통해 구현되며, 데이터 수를 2배로 확장하면서 방향 편향을 완화한다. 다음으로, 클래스 불균형 완화를 위해 sitting과 standing 클래스에 가우시안 지터(Gaussian jitter)를 적용하여 각 10개의 추가 샘플을 생성한다. 표준편차 σ 는 신체 부

Table 3. Gaussian jitter standard deviation (σ)

Bone	θ σ (rad)	ϕ σ (rad)
Spine x3	0.05	0.05
Thigh L/R	0.15	0.10
Shin L/R	0.12	0.10
Upper Arm L/R	0.40	0.25
Forearm L/R	0.35	0.25

위의 자유도를 고려하여 Table 3과 같이 설정하였다. 몸통은 작은 σ 로 안정성을 유지하고, 팔은 큰 σ 로 다양성을 확보하였다.

5) 가중 랜덤 샘플러(WeightedRandomSampler) 적용

최종 데이터셋은 Table 4와 같이 클래스 간 샘플 수의 불균형이 존재한다. 이를 완화하기 위해 학습 시 각 샘플에 대해 클래스 빈도의 역수를 가중치로 사용하는 가중 랜덤 샘플러(WeightedRandomSampler)를 적용하였다. 이를 통해 에포크마다 클래스 간 균형 있는 학습이 이루어지도록 하였다.

4.2 실험 환경 및 설정

본 연구의 모든 실험은 NVIDIA RTX 5080 GPU, AMD Ryzen 7 7800X3D CPU, 64GB RAM 환경에서 수행되었으며, PyTorch 2.0 프레임워크를 사용하여 구현하였다. 텍스트 인코더로는 BGE-M3[4] 사전 학습 모델을 사용하였으며, 학습 파라미터는 고정(freeze)한 상태로 임베딩 추출에만 활용하였다. 확산 모델의 학습 설정은 Table 5와 같다.

4.3 평가 지표

생성된 포즈의 품질을 정량적으로 평가하기 위해 의미 일관성, 분포 유사도, 다양성, 뼈 길이 편차의 측면에서 다음 네 가지 지표를 사용한다.

1) 의미 일관성(SC, Semantic Consistency)

SC는 생성된 포즈가 주어진 클래스 조건을 얼마나 정확히 반영하는지를 평가하는 지표이다. 이를 위해 학습 데이

Table 4. Final dataset statistics

Class	Samples	Ratio
sitting	19,316	20.1%
walking	59,928	62.4%
standing	16,804	17.5%
Total	96,048	100%

Table 5. Training configuration

Hyperparameter	Value
Batch size	64
Epochs	300
Learning Rate	3×10^{-4}
Optimizer	AdamW
Diffusion steps T	100
Noise schedule	Linear($\beta_1 = 10^{-4}$, $\beta_T = 0.03$)
Class embedding dim	32
Timestep embedding dim	128
Model parameters	~235K

터의 22차원 방향각 벡터를 기반으로 별도의 분류기(Angle Classifier)를 학습하고, 클래스 조건별로 생성된 포즈 200개에 대해 Top-1 정확도를 계산한다. 분류기는 22D → 128D → 128D → 3D 구조의 MLP로 구성되며, 학습 데이터의 80/20 분할을 사용하였다. 학습된 분류기는 검증 데이터(19,209개)에 대해 Top-1 정확도 96.6% (sitting 98.0%, walking 97.7%, standing 91.3%)를 기록하여 높은 분류 성능을 보였으며, 이를 통해 평가 지표로서의 신뢰성을 확보하였다. 기존 연구에서는 사전 학습된 동작 인식 모델을 활용하는 경우가 많으나[16], 대부분 관절 좌표 기반으로 학습되어 방향각 표현과의 직접적인 호환이 어렵다. 이에 본 연구에서는 동일한 표현 공간에서 학습된 분류기를 사용하여 평가의 일관성과 타당성을 확보하였다. SC 값이 높을수록 생성된 포즈가 의미적으로 일관됨을 의미한다.

2) 분포 유사도(FID, Fréchet Inception Distance)

FID는 실제 데이터 분포와 생성 데이터 분포 간의 거리를 측정하는 지표로[5], 본 연구에서는 22차원 방향각 벡터 공간에서 클래스별 FID를 계산한다. 실제 데이터에서 클래스별로 2,000개를 샘플링하고 생성 데이터 200개와 비교하며, Equation (10)과 같이 정의된다. 여기서 μ_r, Σ_r 는 실제 데이터의 평균과 공분산을 μ_g, Σ_g 는 생성 데이터의 평균과 공분산을 의미한다. 기존 FID는 이미지 특징 공간에서 계산되지만, 본 연구에서는 방향각 표현 공간에서 FID를 계산한다. FID 값이 낮을수록 생성 데이터 분포가 실제 데이터 분포에 더 가까움을 의미한다.

$$FID = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}) \quad (10)$$

3) 다양성 (APD, Average Pairwise Distance)

APD는 동일 클래스에서 생성된 포즈 간 다양성을 측정하는 지표로, 생성된 200개 샘플 간 모든 쌍의 L2 거리의 평균으로 정의된다. 본 연구에서는 실제 데이터로부터 계산한 APD(APD_real)를 기준으로 상대적 다양성을 평가한다. 이를 통해 생성된 포즈가 실제 데이터와 유사한 수준의 다양성을 유지하는지를 확인할 수 있다.

$$APD = \frac{2}{N(N-1)} \sum_{i < j} \|x_i - x_j\|_2 \quad (11)$$

4) 뼈 길이 편차 (BLD, Bone Length Deviation)

BLD는 뼈의 길이가 샘플 간 얼마나 일관되게 유지되는지를 평가하는 지표이다. 각 뼈에 대해 부모 관절과 자식 관절 간의 거리를 계산하고, 전체 샘플에 대한 해당 길이의 편차를 측정한다. BLD는 모든 뼈에 대한 길이 편차의 평균으로 정의되며, 값이 작을수록 뼈 길이가 안정적으로 유지됨을 의미한다. 제안하는 방향각 기반 방법은 forward kinematics 과정에

서 고정된 base pose를 사용하여 뼈 길이가 결정되므로, 이론적으로 BLD가 0에 수렴한다. 반면, 좌표 기반 방식은 각 관절 좌표를 독립적으로 생성하므로 뼈 길이가 일정하지 않으며, 상대적으로 큰 BLD 값을 보인다.

4.4 실험 결과

1) 좌표 기반 모델과의 정량 비교

Table 6은 제안하는 방법과 좌표 기반 베이스라인 모델 간의 정량적 비교 결과를 나타낸다. 공정한 비교를 위해 두 모델의 출력은 동일한 방향각 공간으로 변환하여 평가하였다. SC 결과에서 제안 방법은 90.7%를 기록하여, 좌표 기반 모델(70.2%) 대비 높은 의미 일관성을 보였다. 이는 방향각 기반 표현이 포즈의 구조적 특징을 저차원에서 직접적으로 인코딩함으로써, 클래스 조건을 보다 효과적으로 반영할 수 있음을 의미한다. FID 또한 0.54로, 좌표 기반 모델(8.69) 대비 크게 낮은 값을 기록하여 실제 데이터 분포를 보다 정확하게 모델링함을 확인하였다. APD는 두 방법 모두 유사한 수준을 보였으며, 제안 방법은 다양성을 유지하면서도 보다 안정적인 포즈를 생성하였다. 특히 뼈 길이 편차(BLD)에서 제안 방법은 방향각만을 생성하고 고정된 base pose를 사용하는 구조로 인해 0에 가까운 값을 보였다. 반면, 좌표 기반 모델은 관절 좌표를 독립적으로 생성함에 따라 뼈 길이에 대한 제약이 없어 10.647의 높은 편차를 나타냈다. 좌표 기반 생성이 구조적 제약 없이 관절을 생성하면서 비현실적인 포즈가 발생할 수 있음을 보여준다.

2) 클래스별 성능 분석

Table 7은 제안 방법의 클래스별 정량 평가 결과를 나타낸다. SC 결과에서 walking 클래스는 97.0%로 가장 높은 값을 보였으며, 이는 해당 클래스의 학습 데이터가 상대적으로 충

Table 6. Quantitative comparison between the proposed angle-based model and the coordinate-based baseline in a shared angle space.

Method	SC(↑)	FID(↓)	APD_gen	BLD(↓)
Angle (Ours)	90.7%	0.54	9.01	0.000
Coord (Baseline)	70.2%	8.69	8.52	10.647

* APD_real = 9.17: average pairwise distance of the real training data (diversity reference).

Table 7. Quantitative evaluation results

Class	SC(↑)	FID(↓)	APD_real(GT)	APD_gen
sitting	95.5%	1.38	8.42	8.42
walking	97.0%	1.19	9.31	9.11
standing	79.5%	1.79	9.80	9.51
Overall	90.7%	0.54	-	-

* APD_real(GT): per-class diversity of the real training data, provided as a diversity reference.

분하여 특징적인 패턴을 효과적으로 학습했기 때문에 해석된다. 반면 standing 클래스는 79.5%로 낮은 값을 보였는데, 이는 직립 자세가 다양한 변형을 포함하여 클래스 간 경계가 상대적으로 모호하기 때문에 판단된다. Overall SC 90.7%는 클래스별 SC의 산술 평균으로, 클래스당 동일한 수의 샘플을 생성하여 산출하였다. FID 결과에서도 walking 클래스가 1.19로, 실제 데이터 분포와 가장 유사한 포즈를 생성함을 확인하였다. Overall FID는 클래스별 FID의 단순 평균이 아닌 전체 분포 수준의 유사도를 나타내며, 전체 포즈 분포를 효과적으로 재현하고 있음을 보여준다. APD는 모두 실제와 유사한 수준을 유지하며, 생성된 포즈가 적절한 다양성을 보존하고 있음을 보여준다.

3) 정성적 결과 분석

Fig. 5는 각 클래스 조건에서 생성된 포즈 예시를 보여준다. sitting 클래스에서는 골반이 낮고 무릎이 굽혀진 착석 자세가 생성되었으며, walking 클래스에서는 보폭이 형성되고 팔이 자연스럽게 교차되는 보행 자세가 나타난다. standing 클래스에서는 골반이 높고 다리가 펴진 직립 자세가 안정적으로 생성됨을 확인할 수 있다. 또한 동일 클래스 조건 내에서도 다양한 팔 방향과 세부 자세 변화가 관찰되어, 제안 모델이 포즈의 구조적 일관성과 다양성을 동시에 확보하고 있음을 확인하였다.

Fig. 6은 동일한 텍스트 입력("Generate a sitting human pose")에 대한 생성 결과를 비교한 것이다. 상단은 제안 방법, 하단은 좌표 기반 베이스라인의 결과를 나타낸다. 제안 방법은 입력 조건에 부합하는 앉은 자세를 일관되게 생성한 반면, 좌표 기반 모델은 일부 샘플에서 서 있거나 불완전한 자세를 생성하는 경향을 보인다. 특히 파란색으로 표시된 예시는 입력 조건과 일치하지 않는 포즈가 생성된 사례를 보여준다. 이러한 차이는 포즈 표현 방식의 차이에 기인한다. 방향각 기반 표현은 허벅지와 같은 주요 관절의 방향이 소수의 각도 변수에 직접 대응되므로, 클래스 조건이 저차원에서 효과적으로




Fig. 5. Generated Pose Samples




Fig. 6. Comparison of generated poses conditioned on the same text input ("Generate a sitting human pose")

반영된다. 예를 들어, sitting 자세는 허벅지 방향이 수평에 가까워지는 특징을 가지며, 해당 각도 값의 변화만으로 표현될 수 있다. 반면, 좌표 기반 표현에서는 동일한 자세 표현을 위해 hip, knee, ankle 등 여러 관절 좌표가 동시에 변화해야 하며, 이들 간의 복잡한 상관관계를 학습해야 한다. 그 결과, 조건 제어가 어려워 일부 샘플에서 입력 조건과 일치하지 않는 포즈가 생성된다.

4) 노이즈 스케줄(β_T)의 영향 분석

노이즈 스케줄 끝점(β_T)이 생성 성능에 미치는 영향을 분석하기 위해, β_T 를 0.005에서 0.05까지 변화시키며 SC, FID, APD를 측정하였다. 표준 DDPM[6]은 $\beta_T = 0.02$ 를 기본값으로 사용하나, 본 데이터셋에 최적화된 설정을 탐색하기 위해 추가 실험을 수행하였다. 단, 정확한 비교를 위해 모든 설정을 동일 조건(150 epoch)으로 학습하였으며, 해당 실험 결과인 Fig. 7의 수치는 Table 6(300 epoch)의 결과와 다소 차이가 있을 수 있다. β_T 가 0.005로 지나치게 작을 경우 노이즈가 충분히 주입되지 않아 SC가 66.4%로 급격히 저하된다. $\beta_T = 0.03$ 에서 SC 89.3%로 최고점을 보이며 FID도 양호한 수준을 유지하여, 본 연구에서는 이를 최종 설정으로 채택하였다. $\beta_T = 0.05$ 에서는 FID가 소폭 개선되나 SC가 감소하는 경향을 보




Fig. 7. Effect of Noise Schedule Endpoint(β_T)

여, 과도한 노이즈는 의미 일관성을 저하시킴을 확인하였다. APD는 전 구간에서 안정적으로 유지되었다.

5. 결 론

본 논문에서는 자연어 텍스트로부터 정적 2D 스켈레톤 포즈를 생성하기 위한 방향각 기반 확산 모델을 제안하였다. 기존의 관절 좌표 기반 방식과 달리, 각 뼈대의 방향을 방위각(θ)과 고도각(ϕ)으로 표현하고 이를 생성 공간으로 직접 모델링함으로써 인체의 기하학적 구조를 보다 효과적으로 반영하도록 설계하였다. 또한 텍스트 분류와 포즈 생성을 분리한 2단계 파이프라인을 통해 저차원 공간에서 안정적인 학습이 가능하도록 하였다. 실험 결과, 제안 방법은 의미 일관성과 분포 유사도 측면에서 기존 좌표 기반 방법 대비 우수한 성능을 보였으며, 특히 뼈 길이 편차가 0에 수렴하여 구조적 안정성이 크게 향상됨을 확인하였다. 이러한 결과는 방향각 기반 표현이 인체 구조를 유지하면서도 효율적인 포즈 생성을 가능하게 함을 보여준다. 본 연구는 기존의 좌표 중심 접근과 달리 표현 공간 자체를 재정의함으로써 생성 모델의 구조적 한계를 개선할 수 있음을 제시하며, 향후 다양한 포즈 생성 및 동작 생성 문제에 확장할 수 있을 것으로 기대된다.

References

- [1] G. Tevet, S. Raab, B. Gordon, Y. Shafir, D. Cohen-Or, and A. H. Bermano, "Human motion diffusion model," in *Proceedings of the International Conference on Learning Representations*, 2023.
- [2] M. Zhang et al., "MotionDiffuse: Text-driven human motion generation with diffusion model," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol.46, No.6, pp.4115-4128, 2024.
- [3] C. Guo et al., "Generating diverse and natural 3D human motions from text," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp.5152-5161, 2022.
- [4] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, and Z. Liu, "M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation," in *Findings of the Association for Computational Linguistics: ACL 2024, Bangkok, Thailand*, pp.2318-2335, 2024.
- [5] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter, "GANs trained by a two time-scale update rule converge to a local Nash equilibrium," in *Advances in Neural Information Processing Systems*, Vol.30, pp.6626-6637, 2017.
- [6] J. Ho, A. N. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," in *Advances in Neural Information Processing Systems*, Vol.33, pp.6840-6851, 2020.
- [7] A. Q. Nichol and P. Dhariwal, "Improved denoising diffusion probabilistic models," in *Proceedings of the 38th International Conference on Machine Learning*, Vol.139, pp.8162-8171, 2021.
- [8] M. Petrovich, M. J. Black, and G. Varol, "Action-conditioned 3D human motion synthesis with transformer VAE," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp.10965-10975, 2021.
- [9] S. Hong, C. Kim, S. Yoon, J. Nam, S. Cha, and J. Noh, "SALAD: Skeleton-aware latent diffusion for text-driven motion generation and editing," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 7158-7168, 2025.
- [10] X. Chen et al., "Executing your commands via motion diffusion in latent space," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp.18000-18010, 2023.
- [11] M. Zhang et al., "ReMoDiffuse: Retrieval-augmented motion diffusion model," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp.364-373, 2023.
- [12] B. Jiang, X. Chen, W. Liu, J. Yu, G. Yu, and T. Chen, "MotionGPT: Human motion as a foreign language," in *Advances in Neural Information Processing Systems*, Vol.36, pp.20067-20079, 2023.
- [13] G. Delmas, P. Weinzaepfel, T. Lucas, F. Moreno-Noguer, and G. Rogez, "PoseScript: Linking 3D human poses and natural language," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol.47, No.7, pp.5146-5159, 2025.
- [14] N. Mahmood, N. Ghorbani, N. F. Troje, G. Pons-Moll, and M. J. Black, "AMASS: Archive of motion capture as surface shapes," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp.5442-5451, 2019.
- [15] C. Guo et al., "Action2Motion: Conditioned generation of 3D human motions," in *Proceedings of the ACM International Conference on Multimedia*, pp.2021-2029, 2020.
- [16] A. Ismail-Fawaz, M. Devanne, S. Berretti, J. Weber, and G. Forestier, "Establishing a unified evaluation framework for human motion generation: A comparative analysis of metrics," *Computer Vision and Image Understanding*, Vol.254, pp.104337, 2025.



권 보 미

<https://orcid.org/0009-0000-6274-0977>
e-mail : bomi9970@sookmyung.ac.kr
2025년 숙명여자대학교 통계학과(학사)
2025년~현 재 숙명여자대학교
컴퓨터과학과(석사)
관심분야: 인공지능, 딥러닝, 빅데이터, 생성 AI



이 기 용

<https://orcid.org/0000-0003-2318-671X>
e-mail : kiyonglee@sookmyung.ac.kr
1998년 KAIST 전산학과(학사)
2000년 KAIST 전산학과(석사)
2000년 KAIST 전산학과(박사)
2006년~2008년 삼성전자 책임연구원

2008년~2010년 KAIST 전산학과 연구조교수
2010년~현 재 숙명여자대학교 소프트웨어학부 교수
관심분야: 데이터마이닝, 딥러닝, 데이터베이스, 빅데이터