

딥러닝 모델을 이용한 고주파 연소 불안정 조기 감지

한경현[†] · 김규태

한국과학기술원 항공우주공학과

Early Detection of High-Frequency Combustion Instability Using Deep Learning Model

Gyeonghyun Han and Kyu Tae Kim

Department of Aerospace Engineering, Korea Advanced Institute of Science and Technology

(Received 26 March 2026, Received in revised form 21 April 2026, Accepted 21 April 2026)

ABSTRACT

This study examines the feasibility of real-time early detection of combustion instability using a ResNet-18 model trained on recurrence plot images derived from dynamic pressure signals. Experiments were conducted in a hydrogen-fueled premixed combustor by gradually increasing the fuel flow rate from three stable initial velocities, which induced several high-frequency instability modes. A model trained on a single mode could detect instability onset, but its performance depended on the frequency difference between the trained and target instability modes. A combined-frequency model showed effective detection performance, although improper frequency selection caused overly sensitive responses in stable regions. These results indicate that robust early detection requires not only multi-band training, but also careful selection of representative instability frequencies.

Key Words : Combustion instability, Hydrogen, Early detection, Deep learning, Recurrence plot

1. 서 론

온실가스 배출 규제에 대처하기 위한 가스터빈 산업계의 대표적인 전략 중 하나로 희박 예혼합 연소 기술이 널리 활용되고 있다[1-3]. 희박 예혼합 연소는 연료를 이론 당량비 기준보다 낮게 공급하여 화염 온도를 낮추고, 이에 따라 확산 화염에서 나타나는 국부적인 고온 영역 없이 균일한 연소 환경을 조성하여 열적 질소산화물의 배출을 억제하는 장점을 가진다. 하지만 이를 위해서는 연소기를 가연 한계에 가까운 불안정한 상태에서 운전하여야 하는데 이 경우 연소기 내부의 음향장과 불안정한 화염의 열방출률 섭동이 상호작용하며 연소기 내부 압력이 크게 증가하는 연소 불안정 현상이 발생하기 쉬운 환경이 조성된다

[4,5]. 이러한 현상은 연소기의 운용에 제약을 줄 뿐만 아니라, 구조물의 피로 수명에도 부정적인 영향을 미치기 때문에 개발 단계에서 이를 회피할 수 있는 전략을 마련하는 것이 매우 중요하다. 특히 최근에는 연료의 무탄소화 기조에 따라 수소 연료가 차세대 에너지원으로 조망받고 있는데, 높은 반응성과 확산성 등 수소 화염의 특성에서 기인한 고주파 불안정이 중요한 연구 주제로 부상하고 있다 [6-10].

안정적인 연소기 운용을 위해서는 연소 불안정의 발생 메커니즘과 시작 시점을 사전에 분석하고 예측하는 것이 중요하다. 이에 다양한 신호 분석 기법을 통해 연소 상태를 진단하고 더 나아가 불안정을 초기에 감지하려는 연구가 다수의 연구 그룹에서 이루어져 왔다. Choi 등[11]은 수소/메탄 혼소 실험에서 획득한 압력 신호의 파형을 세 가지 증가-감소 패턴으로 분류하여 분석하였으며, 연소기 시스템이 한계 진동(limit cycle) 구간으로 천이할 때 파형 패턴의 분포 역시 특정 값으로 수렴함을 확인하였다. Jang 등[12]은 네 가지 시계열 분석 기법을 이용하여 수소/메탄

[†]Corresponding Author, ghhan@kaist.ac.kr

This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/4.0>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

혼소 조건에서 발생한 불안정을 분석하였고, 시간 첨도(temporal kurtosis)를 활용한 방법이 Root Mean Square (RMS) 분석보다 이른 시점에 불안정을 감지할 수 있으며 다른 기법들과 병행할 경우 정확도 측면에서도 개선을 기대할 수 있음을 보였다. Hashimoto 등[13]은 Large Eddy Simulation(LES)을 통해 수소 화염의 거동을 분석하고 압력과 열방출률의 동위상 여부를 판별하는 변수를 정의하여 해당 변수의 섭동이 연소 불안정 발생의 선행 인자로 나타남을 보였다. Meloni 등[14]은 압력 신호를 동적모드분해(dynamic mode decomposition) 기법 기반의 저차원 모델로 분석하여 압력 신호의 성장률이 양수로 지속되는 시간을 기준으로 연소 불안정을 조기 감지할 수 있음을 보였다.

한편, 최근에는 이러한 신호 분석 기반의 불안정 조기 감지에 딥러닝 기법을 접목하려는 시도가 활발히 이루어지고 있다. Cellier 등[15]은 Convolutional Recurrent Neural Network(CRNN) 모델을 활용하여 연소기 운전 변수의 변화량을 학습한 뒤, 학습된 신경망을 통하여 미지의 실험 조건에서의 불안정 발생 가능성을 예측할 수 있음을 보였다. Sarkar 등[16]은 고속 카메라로 촬영한 화염 이미지를 Deep Belief Network(DBN) 모델과 시계열 패턴 분석을 통해 분석하였으며, 딥러닝 모델이 인식하는 버섯 모양의 와류 구조를 불안정 조기 감지에 활용할 수 있음을 보였다. Xu 등[17]은 실제 불안정 데이터를 충분히 확보하기 어려운 현실을 고려하여 생성형 모델을 사용해 단일 실험 신호로부터 합성 신호를 생성한 뒤, 이를 활용하여 호프 분기(Hopf bifurcation) 구간을 인식하는 기법을 제시하였다. Bury 등[18]은 동역학계에서 생성한 시계열 데이터를 딥러닝 모델에 학습시켜 분기점의 조기정보와 유형 판별이 가능함을 보였고, Rijke tube 실험 데이터를 통해 이를 연소 시스템에 적용할 수 있음을 확인하였다.

많은 선행 연구에도 불구하고 가스터빈의 가혹한 운전 조건에서 수집 가능한 데이터의 한계와 다양한 운전 변수에 따른 시스템의 복잡성으로 인해 연소 불안정을 조기에 예측할 수 있는 범용적 시스템의 구현에는 여전히 추가적인 연구가 필요한 실정이다. 이에 본 연구에서는 연소실 압력 신호를 학습한 딥러닝 모델을 이용하여 수소 예혼합 화염에서의 연소 불안정 발생 시점 예측 가능성을 검증하였다. 이를 위해 모형 가스터빈 연소기를 사용하여 수소 연료 유량 증가에 따른 연소 불안정의 발생 양상을 실험적으로 관찰하였으며, 획득한 압력 신호를 바탕으로 딥러닝 모델을 학습시켜 모델이 연소 불안정 발생 시점을 사전에 예측할 수 있는지 분석하였다.

2. 실험 장비 및 분석 기법

2.1 모형 가스터빈 연소기

Fig. 1(a)는 본 연구에서 데이터 획득에 사용한 모형 가스터빈 연소기의 단면도로, 상세 제원은 기존 연구에서 활용한 것과 동일하다[19]. 반응물의 경우 전기 히터를 통해 가열한 상압의 공기를 순도 99.999%의 수소와 혼합하여 공급하였으며, 해당 연료/공기 혼합물은 인젝터 덤프면까지 도달하는 과정에서 충분히 혼합되며 완전 예혼합 조건을 형성한다. 반응물은 인젝터 덤프면으로부터 상류 방향으로 333 mm 이격된 초크 오리피스를 지나 슬릿 형태의 인젝터를 통해 연소실 내부로 분사된 후 점화되는데, 이때 연소실 벽면은 원통형 석영관으로 제작하여 화염 가시화를 가능하게 하였다. 연소실 하류의 연소 생성물은 이동 가능한 피스톤으로 막힌 경계를 지나 외부로 배출되는데, 피스톤과 상류의 초크 오리피스가 본 연소기의 음향학적 닫힘-닫힘(acoustically closed-closed) 경계면을 형성한다. Fig. 1(b)는 연소기 인젝터를 하류 방향에서 관측한 형상으로, 폭 1.5 mm의 슬릿 구조가 원주 방향, 반경 방향으로 조합된 구조이다. 이러한 슬릿 구조는 수소 화염의 역화를 방지하는데 특화되어 있는데, 본 연구에서는 역화로 인한 운전 한계를 최소한으로 하며 선행 연구에서 확인된 것과 유사한 상압 고주파 불안정을 관측하기 위해 해당 인




Fig. 1. (a) Cross-sectional view of the model gas turbine combustor. (b) Injector configuration and arrangement of the dynamic pressure sensors. Modified from[19].

벡터를 활용하였다[19]. 연소기 덤프면에는 5개의 동압 센서(PCB piezo electronics, 112A22)들을 원주 방향으로 설치하여 동압 신호를 계측하였으며, 각 센서들은 횡방향 불안정 발생 시 이를 특정하기 위해 90° 및 30° 간격을 두고 배치하였다.

본 연구에서는 과도 응답 실험을 수행하여 시간에 따른 불안정 발생 양상을 분석하고, 여기서 얻어진 데이터를 딥러닝 모델을 통해 학습하여 불안정 시작 시점 예측이 가능한지 검증하였다. 모든 실험은 순도 99.999%의 수소 전소 예혼합 환경에서 수행되었으며, 연소실로 분사되는 반응물의 온도는 473 K으로 고정하였다. 이 상태에서 20초간 수소 공급량을 서서히 증가시켜 단열 화염 온도를 1400 K부터 2000 K까지 상승시켰는데 해당 온도에서의 당량비는 0.325에서 0.615 수준이다. 실험은 여러 유속 조건에서 수행하여 그 중 안정에서 불안정으로의 천이가 관측된 초기 노즐 유속 20, 25, 35 m/s의 세 가지 조건을 분석하였다. 이때 연소기 길이는 1400 mm로 고정하였다.

2.2 인공신경망 기반 이미지 분석 기법

실험에서 획득한 압력 신호를 분석하기 위해 Recurrence Plot(RP)과 ResNet-18 딥러닝 모델을 사용하였다. RP는 시계열 신호의 각 시점 간 유사성을 비교함으로써 동적 시스템의 주기성을 2차원 정사각 행렬 형태로 시각화하는 기법으로, 육안으로는 식별하기 어려운 미세한 규칙성을 추출하는데 효과적이다[20,21]. 본 연구에서는 연소기 덤프면의 서로 다른 세 위치($p'_{c,1}$, $p'_{c,2}$, $p'_{c,4}$)에서 48 kHz로 획득한 압력 신호로부터 각각 224개의 데이터를 추출하여 RP 생성에 활용하였으며, 이는 약 4.7 ms에 해당한다. 90° 간격으로 배치된 세 가지 센서의 데이터를 활용하는 것은 횡방향 불안정 발생 시 나타날 수 있는 압력 신호 간의 위상차를 학습에 반영하기 위함이다. 또한 데이터 길이를 224로 제한한 것은 실시간 감지가 가능하도록 계산량을 줄이는 한편 분석에 사용된 ResNet-18 모델의 입력 이미지 크기인 224×224 를 고려한 것으로, 이 길이는 본 실험에서 발생한 1.8 kHz의 최저 주파수 대역 불안정 상황에서도 8주기 이상의 반복성을 포함할 수 있을 만큼 충분히 긴 시간이다. 본 연구에서는 특별히 비이진화 RP(non-binarized RP)를 사용하였는데, 이는 이진화 RP를 사용하였을 때 임계값 이하의 강도로 발생하는 고조파나 미세 진동 특성이 소실되는 것을 방지하기 위함이다. 또한 신호의 세기가 학습에 미치는 영향을 최소화하기 위해 모든 RP 성분은 개별 이미지의 최대값을 기준으로 정규화하였다. 최종적으로 $p'_{c,1}$, $p'_{c,2}$, $p'_{c,4}$ 위치에서 획득한 데이터로 생성

된 RP를 각각 RGB 채널에 할당하여 학습용 이미지를 생성하였다.

생성된 RP 이미지들의 학습에 사용된 ResNet-18 딥러닝 모델은 Fig. 2에서 보이는 바와 같이 18개의 층으로 구성된 비교적 경량화된 구조의 모델로 연산량이 적고 학습 속도가 빠르다는 장점을 가지고 있어 연소 불안정 조기 감지라는 연구 목적에 잘 부합한다[22]. 본 연구에서는 각 운전 조건에서 계측한 압력 신호를 대상으로 압력 섭동의 RMS 값이 대기압의 0.1% 이하인 구간을 안정 구간으로, 1% 이상인 부분을 불안정 구간으로 정의하였다. 이를 바탕으로 각 구간에서 500장씩의 RP 이미지를 생성하여 딥러닝 모델 학습에 활용하였다. 이와 같이 구성된 학습 데이터는 안정 상태와 불안정 상태 간의 특성이 명확히 구분되므로, 디폴트 하이퍼파라미터를 사용한 경우에도 테스트




Fig. 2. Architecture of ResNet-18 deep learning model. Modified from[22].

Table 1. Model configuration

Parameter	Value
Network architecture	ResNet-18
Input size	$224 \times 224 \times 3$
Number of classes	2
Learning rate	0.001
Batch size	32
Epochs	2

트 데이터로 검증 시 2 epochs 이내에 100%의 분류 성능을 나타내었다. 이는 해당 분류 문제가 하이퍼파라미터 설정에 민감하지 않은 비교적 명확하게 분리 가능한 문제임을 의미한다. 본 연구의 목적은 이렇듯 명확히 구분되는 상태 간의 분류 성능을 향상시키는 것이 아니라, 명확한 안정 상태와 불안정 상태만을 학습한 모델이 천이 구간에서 나타나는 모호한 데이터를 어떻게 인식하는지 분석하는 데 있다. 따라서 천이 구간 데이터를 이용한 하이퍼파라미터 튜닝은 데이터 누수(data leakage)를 야기할 가능성이 있어 추가적으로 수행하지 않았으며 기본적인 모델의 특성 및 하이퍼파라미터 수치는 Table 1에 제시하였다.

3. 실험 결과 및 고찰

3.1 시계열 신호 및 불안정 특성

Fig. 3은 초기 유속별 당량비 증가에 따른 연소 불안정 발생 양상을 보여주는 그래프이다. Case 1, 2, 3은 각각 초기 노즐 유속이 20, 25, 35 m/s일 때의 조건을 나타낸다. 각 조건별로 상단에 위치한 3개의 그래프는 연소가 덤프면을 따라 배치된 동압 센서에서 측정한 압력 신호의 변화 추세를, 아래에 위치한 두 개의 그래프는 동일 시간대에 대한 불안정 주파수의 스펙트로그램과 실시간 당량비 증가량을 나타낸다. 우선 전체적인 압력의 변화 추세를 보면, 동압 센서들은 원주 방향으로 분산 배치되어 있으나, 축

방향으로는 동일한 덤프면에 위치하므로 각 조건에서 전반적으로 유사한 변화 양상을 보이는 것을 알 수 있다. 다만 동일한 신호들의 주요 불안정 신호 발생 영역을 짧은 시간 범위에서 확대하여 나타낸 Fig. 4(a)에서 볼 수 있듯이 모든 신호가 항상 동위상으로 움직이는 것은 아니며, 이는 지배적인 주파수에 따라 다른 형태의 불안정이 발생함을 보여준다.

각 조건의 스펙트로그램을 자세히 살펴보면, 초기 유속 조건에 따라 불안정 주파수가 다양하게 발생하는 것을 알 수 있다. 우선 Fig. 3(a)의 초기 유속 20 m/s 조건에서는 저당량비 구간에서 안정한 상태를 유지하다가 9초를 기점으로 2.6 kHz 대역의 불안정이 발생하였다. Fig. 3(b)의 초기 유속 25 m/s 조건에서는 저당량비 구간부터 압력 신호 진폭은 낮은 수준을 유지하지만, 미약한 주파수 성분이 검출되는데, 이는 음향장이 화염과 결합하고 있으나 아직 충분히 성장하지 못한 상태임을 시사한다. 이후 당량비가 증가함에 따라 시스템은 10초 전후에서 2.6 kHz 불안정과 결합하였고, 최종적으로는 peak-to-peak 진폭 1.5 kPa 수준의 3.2 kHz 대역 불안정으로 천이하였다. 한편, 간헐적으로 3.2 kHz와 3.6 kHz 대역의 불안정이 동시에 발생하는 경우에는 peak-to-peak 진폭이 5 kPa 이상으로 크게 증가하는 burst 현상이 관찰되었다. 마지막으로 Fig. 3(c)의 초기 유속 35 m/s 조건에서는 당량비 증가에 따라 1.8 kHz의 불안정을 거쳐 2.6 kHz와 3.2 kHz 대역의 불안정이 번갈




Fig. 3. Transient evolution of dynamic pressure signals at different azimuthal locations in the combustor, along with the corresponding spectrograms (calculated from $p'_{c,i}$) and equivalence ratio. Each column corresponds to a different initial velocity of 20, 25, and 35 m/s.

아 발생한 후, 최종적으로는 두 주파수 대역이 동시에 관찰된다.

Fig. 4(a)는 Fig. 3의 각 조건 최상단 패널에 표시된 $t_1 \sim t_4$ 시점을 기준으로 추출한 4주기 구간의 압력 신호를 지배적인 주파수 대역으로 대역통과 필터링한 결과이다. 초기 유속 25 m/s 조건의 t_1 시점에 발생한 2.6 kHz 불안정과 초기 유속 35 m/s 조건의 t_3 시점에 발생한 1.8 kHz 불안정의 경우, 모든 위치에서의 신호가 동위상으로 진동하며, 이를 통해 길이 방향 모드에 결합한 불안정이 발생하였음을 확인할 수 있다. 그래프에는 제시하지 않았으나, 35 m/s 조건의 t_4 시점에서 발생한 2.6 kHz 불안정 역시 길이 방향 모드에 결합한 것으로 확인되었다. 반면, 25 m/s 조건의 t_2 시점과 35 m/s 조건의 t_4 시점에서 발생한 3.2 kHz 대역의 불안정은 압력 신호들이 서로 위상차를 가지며 거동하는 특징을 보인다.

압력 신호들이 동위상으로 거동하지 않는 t_2 및 t_4 시점의 3.2 kHz 불안정 특성을 보다 상세히 파악하기 위해 압력 신호를 시계 및 반시계 방향으로 회전하는 진행파로 분해하고 각각의 진폭을 Fig. 4(b)에 확률밀도함수 형태로 나




Fig. 4. (a) Pressure perturbation signals measured over four oscillation cycles at five different azimuthal positions on the dump plane. (b) Joint probability density function of the amplitudes of the clockwise and counter-clockwise-traveling waves, A_- and A_+ respectively. The dashed lines indicate spin-ratio values of $\pm 1/3$.

타내었다. 해당 그래프에서 압력 진폭의 분포가 대각선 방향에 집중될 경우, 마디선(nodal line)이 고정된 정상파 형태의 섭동이 지배적임을 의미한다. 반면, 파선을 기준으로 바깥쪽 영역에 분포가 집중될 경우에는 한쪽 방향으로 진행되는 파동의 세기가 우세함을 의미하며, 이는 회전 모드의 발생을 나타낸다[23]. 좌측에 제시된 t_2 시점으로부터 1초 구간에 대한 확률밀도함수 분포는 파선 내부의 정상파 모드 영역에 주로 분포하며, $p'_{c,1}$, $p'_{c,5}$ 그룹과 $p'_{c,2}$, $p'_{c,3}$, $p'_{c,4}$ 그룹이 각각 동위상으로 거동하는 것으로 보아 수평 마디선을 가지는 횡방향 모드에 결합한 불안정이 발생한 것으로 추정된다. 한편 t_4 시점의 경우에는 t_2 시점에 비해 신호 간 위상차가 보다 복잡하게 나타난다. 또한 우측에 제시된 확률밀도함수에서도 정상파 영역에 국한되지 않은 넓은 분포가 보이는데, 이는 당량비가 지속적으로 증가하는 과정에서 완전한 한계 진동이 형성되지 못하였을 뿐 아니라, 동시에 발생한 2.6 kHz 불안정 신호의 간섭에 기인한 것으로 판단된다.

이러한 차이를 바탕으로, 각 영역에서 뚜렷하게 나타난 세 가지 대표 주파수 대역인 2.6 kHz, 3.2 kHz, 1.8 kHz의 불안정 구간으로부터 추출한 데이터를 이용하여 딥러닝 모델을 학습하였으며, 이를 통해 전체 시스템의 안정성을 판별하였다. 학습에 사용된 데이터의 추출 구간은 Fig. 3의 스펙트로그램에 백색 파선으로 표기하였다.

3.2 단일 주파수 학습 모델

Fig. 5는 20 m/s 조건의 일부 구간에서 학습한 데이터를 바탕으로 해당 신호의 불안정 발생 여부를 판별한 결과를 나타낸다. Fig. 5(a)에서 흑색 선은 압력 섭동을, 녹색 선은 압력 섭동의 RMS 값을 나타낸다. 또한 압력 섭동의 RMS 값이 증가하여 대기압의 0.1%를 처음 초과하는 시점을 시간축의 0으로 정의하였는데, 본 연구에서는 딥러닝 모델이 불안정 발생을 처음 예측한 시점을 RMS 0.1% 도달 시점과 비교하여 더 이른 시점에 예측한 경우를 연소불안정의 조기 감지에 성공한 것으로 정의하였다. Fig. 5(a)와 Fig. 5(c)에 공통적으로 표시된 회색 음영 영역은 각각 안정 구간과 2.6 kHz 불안정 구간을 의미하며, 해당 영역에서 각각 500장의 이미지를 추출하여 안정/불안정의 이진 분류 학습에 사용하였다. Fig. 5(b)는 압력 신호의 성장에 따른 대표적인 RP 이미지를 나타낸 것으로, 안정 상태, RMS 0.1% 도달 시점, 그리고 불안정 상태에서 서로 다른 패턴이 나타남을 보여준다. 특히 RMS 0.1% 도달 시점의 이미지는 안정 상태와 확연히 구분되는 패턴을 보인다. Fig. 5(c)는 RP 이미지를 학습한 모델이 시간에 따라 판별




Fig. 5. (a) Evolution of the pressure fluctuation, with the RMS value indicated by the green line. (b) Representative recurrence plots for the stable state, onset of instability, and limit-cycle condition, denoted as points A, B, and C, respectively. (c) Combustor stability determined using a ResNet-18 deep learning model trained on the gray-shaded region.

한 시스템의 안정 상태를 나타낸다. 학습에 사용되지 않은 두 회색 영역 사이의 천이 구간에서 모델은 진폭이 본격적으로 상승하기 약 0.04초 전에 불안정 발생을 감지하였으며, 최초로 불안정을 감지한 이후에는 시스템을 지속적으로 불안정 상태로 판별하였다.

딥러닝 모델의 특성상 학습에 사용한 신호 자체를 대상으로 판별할 경우, 100%에 가까운 정확도를 보이는 것은 자연스러운 결과이다. 그러나 실제 연소 불안정은 연소기 형상이나 운전 조건에 따라 다양한 주파수 대역에서 발생하기에 각 조건에서 발생한 불안정을 학습한 모델을 이용하여 서로 다른 조건의 신호를 테스트하였으며, 이 경우 시스템의 안정 상태에 대한 판별 결과는 다소 복잡한 양상을 보임을 Fig. 6에서 확인할 수 있다. 해당 그래프들은 Fig. 3의 백색 파선으로 표시된 영역의 불안정 신호를 학습한 모델을 사용하여 서로 다른 조건의 시스템 안정성을 판별한 결과를 나타내며 자홍색 선은 압력의 RMS 값을, 흑색선은 불안정 판별 결과를 나타낸다. 예를 들어, 최상단 행의 그래프는 35 m/s 조건에서 발생한 1.8 kHz 불안정을 학습한 모델을 20 m/s 조건인 Case1 신호에 적용한 결




Fig. 6. RMS value of the pressure signal and combustor stability determined by deep learning models trained on different instability frequency bands. Green circles denote the initial detection times corresponding to the point where the RMS amplitude reaches 0.1%.

과이다. 이때 시간축은 Fig. 5와 동일하게 압력 섭동의 RMS 값이 0.1%에 도달하는 시점을 0초로 정의하였으며, 시각화를 용이하게 하기 위해 전후 4초 구간만을 도시하였다. 제시된 영역은 Fig. 3에 녹색 파선으로 표시된 구간과 동일하다.

우선 상단의 두 패널을 보면, 동일한 20 m/s 조건의 신호를 분석하였음에도 불구하고 1.8 kHz 불안정을 학습한 모델은 안정 영역에서 나타나는 미세한 1.0 kHz 대역의 섭동을 불안정 신호로 식별한 반면, 3.2 kHz 불안정을 학습한 모델은 진폭이 상승하기 약 0.02초 전에 불안정을 판단하였다. 이는 RMS 값이 0.1% 미만인 안정 구간에서 발생한 미세 섭동 주파수와 학습 주파수 간의 차이가 작을 경우, 모델이 해당 신호에 대해 민감하게 반응할 수 있음을 시사한다. 중간의 3, 4행에 제시된 25 m/s 조건의 판별 결과에

서는 RMS 값이 서서히 증가하는 초임계 분기(super-critical bifurcation) 거동이 관찰된다. 이 경우 1.8 kHz 불안정을 학습한 모델과 2.6 kHz 불안정을 학습한 모델은 모두 불안정을 수 초 이상 앞서 조기 감지하는 데 성공하였다. Fig. 3(b)의 스펙트로그램에서 확인할 수 있듯이 3.2 kHz 불안정이 지배적으로 발달하기 앞서 1.8 kHz 및 2.6 kHz 대역의 미세한 불안정 성분이 순차적으로 나타나는 것으로 보아, 특정 주파수 대역을 학습한 모델이 해당 주파수 성분의 초기 불안정 징후를 적정 수준의 민감도로 포착한 것으로 해석할 수 있다. 또한 20 m/s 조건과 달리 모델이 안정 영역에서 나타나는 미세한 1.0 kHz 대역 섭동에는 반응하지 않는 점으로부터, 해당 모델들이 목표하지 않은 주파수 성분에 대해 과도하게 민감하지 않은 안정적인 판별 특성을 보임을 알 수 있다. 한편 5, 6행의 35 m/s 조건 판별 결과를 보면, 2.6 kHz 불안정을 학습한 모델은 25 m/s 조건에서 나타난 낮은 진폭의 1.0 kHz 대역 섭동에는 반응하지 않았으나, 35 m/s 조건에서 발생한 1.0 kHz 미세 섭동은 불안정으로 판별하였다. 이는 35 m/s 조건에서 관측된 1.0 kHz 대역 섭동의 세기가 25 m/s 조건에서 나타난 섭동보다 더 크기 때문으로 보이며, 이러한 차이는 스펙트로그램의 비교를 통해서도 확인할 수 있다. 반면 3.2 kHz 불안정을 학습한 모델이 미세한 섭동을 일관되게 감지하지 못하는 점을 고려하면, 학습 주파수와 차이가 큰 주파수 대역에서 발생하는 불안정에 대해서는 딥러닝 모델의 감지 성능이 저하될 가능성이 있는 것으로 판단된다.

앞서 설명한 내용의 정량적 평가를 위해 Fig. 6에서 RMS가 0.1%를 초과한 이후의 구간인 0~4초에 해당하는 800개의 데이터를 이용하여 혼동행렬(confusion matrix)을 구성하고, 이를 Table 2에 나타내었다. 본 연구의 목적은 불안정 상태를 감지하는 것이므로 불안정 상태를 양성(positive)으로 정의하였다. 이에 따라 True Positive(TP)는 불안정을 올바르게 감지한 경우, True Negative(TN)는 안정 상태를 올바르게 판단한 경우, False Positive(FP)는 안정 상태를 불안정으로 오판한 경우, False Negative(FN)는 불안정을 안정으로 오판한 경우를 의미한다.

20 m/s 조건의 경우 FP와 TN이 모두 0으로 나타났는데, 이는 0초 이후 압력 섭동이 지속적으로 임계값 이상의 세기를 유지하기 때문이다. 반면 25 m/s 및 35 m/s 조건에서는 불안정 구간 중에도 압력 RMS 값이 일시적으로 0.1% 이하로 감소하는 구간이 존재하며, 해당 구간의 비율은 각각 28% 및 4% 수준으로 나타났다. 일반적으로는 TN과 TP가 높고 FP와 FN이 낮을수록 모델의 분류 성능이 우수하다고 평가할 수 있다. 그러나 본 연구에서 제안하는 모

Table 2. Confusion matrix of the results shown in Fig. 6.

Case1 $(u_{\text{nozzle}} = 20 \text{ m/s})$	1.8 kHz model		3.2 kHz model	
	762	38	357	443
	0	0	0	0
Case 2 $(u_{\text{nozzle}} = 25 \text{ m/s})$	1.8 kHz model		2.6 kHz model	
	547	26	390	183
	161	66	19	208
Case 3 $(u_{\text{nozzle}} = 35 \text{ m/s})$	2.6 kHz model		3.2 kHz model	
	690	78	0	32
	5	27	634	134
Notation	$n = 800$	Predicted: Unstable	Predicted: Stable	
	Actual: Unstable	TP	FN	
	Actual: Stable	FP	TN	

델은 조기 감지를 목적으로 하므로, 예측 시점에서 안정 상태로 보이더라도 단시간 내에 불안정으로 전이될 가능성이 있는 경우 이를 불안정으로 판단하는 것이 보다 적절하다. 실제로 Fig. 6에서 확인할 수 있듯이, 0초 이후 압력이 순간적으로 감소하더라도 곧 다시 불안정 상태로 회복되는 경향이 나타난다. 따라서 불안정 이후 구간의 데이터만을 이용하여 구성된 혼동행렬에서는 FP로 분류된 일부 사례가 실제로는 유효한 조기 감지에 해당할 수 있으며, 이 경우 FP와 TP의 비율이 높은 모델이 오히려 우수한 성능을 보일 가능성이 있다. 이러한 관점에서 보면, 대부분의 조건에서는 FP와 TP의 합이 약 87% 수준으로 나타난 반면, 20 m/s 조건과 3.2 kHz 모델의 조합 및 25 m/s 조건과 2.6 kHz 모델의 조합에서는 불안정 판정 비율이 상대적으로 낮게 나타남을 확인할 수 있다. 25 m/s 조건의 경우, 2~3초 구간에서 압력의 절대값 감소와 함께 기울기 또한 완만해지는 특성이 나타나며, 이 구간에서 2.6 kHz 모델이 시스템을 안정으로 판단하는 경우가 집중되었다. 반면 20 m/s 조건에서는 전반적으로 불안정 상태에 대한 판별 성능이 저하된 경향을 보인다. 이러한 한계는 모델이 시간에 따른 변화 양상을 충분히 반영하지 못하고, 각 시점의 예측값에만 기반하여 판단을 수행하기 때문으로 보이는데, 이는 시간적 의존성을 반영할 수 있는 순환 신경망(recurrent neural network) 계열 모델 등을 활용 시 개선할 수 있을 것으로 기대된다.

3.3 복합 주파수 학습 모델

단일 주파수 학습 모델을 이용한 연소 시스템 안정성 판별 결과, 학습 주파수와 분석 주파수 간 차이가 큰 경우 모델의 민감도 특성에 따라 판별 신뢰성이 저하될 수 있음을 확인하였다. 이러한 주파수 의존성을 보다 면밀히 분석하기 위하여, 초기 유속 25 m/s 조건에서 당량비를 증가시키는 동시에 연소기 길이를 1800 mm에서 1400 mm로 조정하여 540 Hz 대역의 낮은 주파수 불안정과 3.2 kHz 대역의 고주파 불안정이 모두 발생하는 신호를 계측하였으며, 이를 Fig. 7(a)에 나타내었다. Fig. 7(c)는 540 Hz 및 3.2 kHz에서 각각 250장의 RP를 추출하여 학습한 복합 주파수 모델의 판별 결과를 보여준다. 해당 모델은 저주파 불안정의 세기가 감소한 이후에도 약 0.47초 동안 시스템을 불안정 상태로 판별하였으며, 고주파 불안정이 발생하기 약 0.89초 전부터 불안정을 감지하였다. 이는 복합 주파수 조건에서 두 주파수 성분을 동시에 학습한 모델이 효과적으로 작

동할 수 있음을 의미한다. 그러나 Fig. 7(d)와 같이 학습 주파수 조합을 540 Hz 및 2.6 kHz로 변경할 경우, 안정 구간에서 나타나는 2.6 kHz 대역의 미세 섭동에 의해 모델이 과민하게 반응하는 한계가 확인되었다. 따라서 다양한 주파수의 불안정이 공존하는 시스템에서는 주요 주파수 성분을 함께 학습하는 전략이 인식 성능 향상에 유리하며, 동시에 안정 상태에서 나타나는 미세 주파수 성분의 반영 정도를 조절하는 것이 모델의 적정 민감도 확보에 중요함을 알 수 있다.

4. 결 론

예혼합 화염의 대표적인 문제인 연소 불안정의 조기 감지는 시스템의 비선형적 특성으로 인해 중요한 연구 과제로 남아 있으며, 최근 다양한 공학 문제에서 활용되고 있는 딥러닝 기법은 이에 대한 유효한 접근법이 될 수 있다. 본 연구에서는 수소 전소 조건에서의 과도 응답 실험 결과를 바탕으로 다양한 주파수 대역의 연소 불안정을 계측하고, Recurrence Plot(RP)과 ResNet-18 딥러닝 모델을 이용하여 불안정의 조기 감지 가능성을 검토하였다. 실험 결과, 슬릿 형상 연소기에서는 초기 유속 및 당량비 조건에 따라 다양한 주파수 대역의 불안정이 발생하였으며, 3 kHz 이하의 주파수 대역에서는 길이 방향 모드에 결합한 불안정이 주로 나타난 반면, 3 kHz 이상의 고주파 대역에서는 횡방향 모드에 결합한 불안정이 지배적으로 관찰되었다. RP와 ResNet-18 모델을 이용한 분석 결과, 학습에 사용된 주파수 성분과 동일하거나 유사한 특성을 갖는 불안정에 대해서는 모델이 불안정 발생 이전의 미세한 징후를 포착할 수 있었으며, 일부 조건에서는 진폭이 본격적으로 증가하기 이전에 불안정을 조기 감지할 수 있었다. 반면, 특정 주파수 대역의 불안정을 학습한 모델을 서로 다른 주파수 특성을 갖는 신호에 적용할 경우, 학습 주파수와 분석 대상 신호의 주파수 차이에 따라 감지 성능이 저하되거나 과민 반응이 나타날 수 있음을 확인하였다. 또한 복수의 주파수 성분을 함께 학습한 복합 주파수 모델의 적용 결과, 주요 주파수 성분을 동시에 반영하는 접근이 복합 불안정 신호에서 감지 성능 향상에 기여할 수 있음을 확인하였다. 그러나 여러 주파수 데이터를 단순히 결합하는 것만으로는 항상 안정적인 판별 성능이 보장되지 않았으며, 안정 상태에서 존재하는 미세 주파수 성분이 학습과정에 반영되는 정도에 따라 모델의 민감도와 판별 안정성이 크게 달라질 수 있음을 확인하였다. 따라서 다양한 주파수 대역의 불안정이 공존하는 연소 시스템에 딥러닝 기반 조기 감지 기법을 적용하기 위해서는, 주요 불안정 주




Fig. 7. (a) Evolution of the pressure fluctuation, with the RMS value indicated by the green line. (b) Corresponding spectrogram. (c) Stability of the combustor measured by ResNet-18 deep learning model trained at 540 Hz and 3.2 kHz instability. (d) Stability of the combustor measured by ResNet-18 deep learning model trained at 540 Hz and 2.6 kHz instability.

파수의 선정뿐 아니라 학습 데이터의 구성, 전처리 방법, 그리고 모델 구조의 개선이 함께 고려될 필요가 있다.

후 기

이 논문은 기후에너지환경부(MCEE)와 한국에너지기술평가원(KETEP)의 지원과(RS-2023-00270080, 수소터빈 연소기 시험평가 기술개발, 기여율 50%), 한국중부발전(주)의 지원(제2025-현장-15호, 복합발전소 가스터빈 연소진동 감시 시스템 개발, 기여율 50%)을 받아 수행된 연구입니다.

References

- [1] T. Asai, S. Dodo, M. Karishuku, N. Yagi, Y. Akiyama, A. Hayashi, Performance of multiple-injection dry low-NO_x combustors on hydrogen-rich syngas fuel in an IGCC pilot plant, *J. Eng. Gas Turbines Power* 137(9) (2015) 091504.
- [2] S.M. Correa, A review of NO_x formation under gas-turbine combustion conditions, *Combust. Sci. Technol.* 87 (1993) 329-362.
- [3] H.H.W. Funke, N. Beckmann, S. Abanteriba, An overview on dry low NO_x micromix combustor development for hydrogen-rich gas turbine applications, *Int. J. Hydrog. Energy* 44(13) (2019) 6978-6990.
- [4] L. Angello, B. Noble, R. Steele, M. Cohen, B. Emerson, Dry low NO_x (DLN) combustion system operability considerations, *ASME Turbo Expo* (2022), paper GT2022-82667.
- [5] T. Lieuwen, B.T. Zinn, The role of equivalence ratio oscillations in driving combustion instabilities in low NO_x gas turbines, *Symp. (Int.) Combust.* 27 (1998) 1809-1816.
- [6] D. Kim, Review on the development trend of hydrogen gas turbine combustion technology, *J. Korean Soc. Combust.* 24(4) (2019) 1-10.
- [7] J. Jung, D. Kim, M.K. Kim, J. Hwang, W.J. Lee, Analysis of combustion instability characteristics of a single-nozzle combustor in a natural gas-hydrogen co-firing gas turbine under varying operating pressures, *J. Korean Soc. Combust.* 30(2) (2025) 27-35.
- [8] H. Paniez, S. Marragou, H. Magnes, T. Schuller, High-frequency thermo-acoustic instability in a dual swirl H₂ burner, *Proc. Combust. Inst.* 40 (2024) 105679.
- [9] H. Kang, K.T. Kim, Combustion dynamics of multi-element lean-premixed hydrogen-air flame ensemble, *Combust. Flame* 233 (2021) 111585.
- [10] J.G. Aguilar, E. Æsøy, J.R. Dawson, The influence of hydrogen on the stability of a perfectly premixed combustor, *Combust. Flame* 245 (2022) 112323.
- [11] S. Choi, D. Kim, Diagnosis of combustion instability using waveform pattern of dynamic pressure signal, *J. Korean Soc. Combust.* 29(1) (2024) 33-38.
- [12] D.J. Jang, S. Joo, M.K. Kim, J. Hwang, M.C. Lee, Novel combustion instability diagnosis method in a hydrogen/natural gas co-firing gas turbine combustor using a combination of four criteria: Temporal kurtosis, permutation entropy, energy of entropy, and zero-crossing rate, *Int. J. Hydrog. Energy* 85 (2024) 773-782.
- [13] T. Hashimoto, H. Shibuya, H. Gotoda, Y. Ohmichi, S. Matsuyama, Spatiotemporal dynamics and early detection of thermoacoustic combustion instability in a model rocket combustor, *Phys. Rev. E* 99(3) (2019) 032208.
- [14] R. Meloni, N. Giannini, Real time precursor calculation for the early detection of combustion instabilities, *J. Eng. Gas Turbines Power* 144(9) (2022), 091016.
- [15] A. Cellier, C.J. Lapeyre, G. Öztarlik, T. Poinso, T. Schuller, L. Selle, Detection of precursors of combustion instability using convolutional recurrent neural networks, *Combust. Flame* 233 (2021) 111558.
- [16] S. Sarkar, K.G. Lore, S. Sarkar, V. Ramanan, S.R. Chakravarthy, S. Phoha, A. Ray, Early detection of combustion instability from hi-speed flame images via deep learning and symbolic time series analysis, *Annual Conference of the PHM Society* (2015), pp. 353-362.
- [17] G. Xu, B. Wang, Y. Guan, Z. Wang, P. Liu, Early detection of thermoacoustic instability in a solid rocket motor: A generative adversarial network approach with limited data, *Appl. Energy* 373 (2024) 123776.
- [18] T.M. Bury, R.I. Sujith, I. Pavithran, M. Scheffer, T.M. Lenton, M. Anand, C.T. Bauch, Deep learning for early warning signals of tipping points, *Proc. Natl. Acad. Sci. U.S.A.*, 118(39) (2021) e2106140118.
- [19] D. Park, K.T. Kim, Rotational symmetry-driven modal dynamics of high-frequency transverse instabilities in a lean-premixed multislit hydrogen

- combustor, Combust. Flame 245 (2022) 112356.
- [20] J.P. Eckmann, S.O. Kamphorst, D. Ruelle, Recurrence plots of dynamical systems, Europhys. Lett. 4(9) (1987) 973-977.
- [21] N. Marwan, M.C. Romano, M. Thiel, J. Kurths, Recurrence plots for the analysis of complex systems, Phys. Rep. 438 (2007) 237-329.
- [22] K. He, X. Zhang, S. Ren, J. Sun, Deep residual learning for image recognition, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016, 770-778.
- [23] J.F. Bourgouin, D. Durox, J.P. Moeck, T. Schuller, S. Candel, Self-sustained instabilities in an annular combustor coupled by azimuthal and longitudinal acoustic modes, ASME Turbo Expo (2013), paper GT2013-95010.

저자정보

한경현

한경현은 카이스트 항공우주공학과 박사과정이며, 관심분야는 수소 연료, 가스터빈 다단연소 시스템 및 연소 불안정이다.



김규태

김규태는 카이스트 항공우주공학과 교수로 재직중이며, 무탄소 발전가스터빈 연소와 항공엔진 주/후기연소기 관련 실험 및 모델링 연구를 진행하고 있다.

